

OTIMIZAÇÃO DE CARTEIRAS COM APRENDIZADO PROFUNDO: UM ESTUDO COMPARATIVO ENTRE MODELOS CNN-TRANSFORMER E MÉDIA-VARIÂNCIA DE MARKOWITZ

Projeto de Pesquisa

Autor: Henri Dolnikoff

Orientador: Wesley Augusto de Freitas Borge

Disciplina: Otimização de Carteiras

Data: Junho de 2025

RESUMO

Este projeto propõe a aplicação de uma arquitetura híbrida CNN-Transformer, denominada DeepStatArb, para otimização de carteiras de investimentos no contexto de arbitragem estatística. O modelo combina redes neurais convolucionais para extração de características com mecanismos de atenção temporal para capturar padrões complexos em resíduos de modelos fatoriais. A metodologia é comparada com o tradicional modelo de média-variância de Markowitz e uma estratégia passiva de buy-and-hold em um universo de 50 ações do S&P 500 durante o período de 2015-2017. Os resultados demonstram superioridade significativa do modelo DeepStatArb, que alcançou Sharpe ratio de 1,75 comparado a 0,97 (Markowitz) e 0,67 (buy-and-hold), com volatilidade substancialmente menor (10,6% vs 15,8% e 14,4%) e drawdown máximo de apenas -7,2%. A pesquisa contribui para o avanço da aplicação de técnicas de aprendizado profundo em finanças quantitativas, demonstrando viabilidade prática para implementação institucional.

Palavras-chave: Otimização de Carteiras; Aprendizado Profundo; CNN-Transformer; Arbitragem Estatística; Modelo de Markowitz.

1. INTRODUÇÃO

1.1 Tema

O presente projeto investiga a aplicação de técnicas avançadas de aprendizado profundo na otimização de carteiras de investimentos, especificamente através do desenvolvimento

de uma arquitetura híbrida CNN-Transformer denominada DeepStatArb (Deep Statistical Arbitrage). A pesquisa foca na capacidade deste modelo de superar métodos tradicionais de otimização, particularmente o modelo de média-variância de Markowitz, em estratégias de arbitragem estatística aplicadas ao mercado acionário norte-americano.

A arquitetura proposta combina a capacidade das redes neurais convolucionais (CNN) de extrair características espaciais complexas com os mecanismos de atenção dos transformers para modelagem temporal sofisticada. Esta abordagem inovadora é aplicada aos resíduos derivados do modelo de cinco fatores de Fama-French, explorando padrões não capturados por métodos tradicionais de análise fatorial.

1.2 Justificativa

A construção de carteiras eficientes permanece como um dos desafios centrais na gestão de investimentos, com implicações diretas para a performance de fundos institucionais e gestoras de recursos. Embora o modelo de Markowitz (1952) tenha representado um marco teórico fundamental, sua aplicação prática é limitada por problemas bem documentados, incluindo alta sensibilidade a estimativas de inputs, tendência à concentração excessiva e instabilidade temporal dos pesos ótimos.

O avanço exponencial das técnicas de aprendizado de máquina nas últimas décadas oferece oportunidades inéditas para superar essas limitações. Especificamente, a combinação de arquiteturas CNN-Transformer tem demonstrado eficácia excepcional em diversos domínios, desde processamento de linguagem natural até visão computacional. Sua aplicação ao domínio financeiro, contudo, permanece sub explorada, particularmente no contexto de otimização de carteiras baseada em arbitragem estatística.

A justificativa econômica desta pesquisa baseia-se na crescente demanda por estratégias quantitativas que possam gerar alfa consistente em mercados cada vez mais eficientes. Gestores institucionais enfrentam pressão constante para entregar retornos ajustados ao risco, enquanto controlam drawdowns e volatilidade. Neste contexto, metodologias que demonstrem capacidade superior de identificação de oportunidades de arbitragem estatística possuem valor prático significativo.

1.3 Problema de Pesquisa

O problema central investigado nesta pesquisa pode ser formulado da seguinte forma:

Podem modelos de aprendizado profundo baseados em arquiteturas CNN-Transformer superar consistentemente o desempenho ajustado ao risco do modelo tradicional de Markowitz em estratégias de arbitragem estatística?

Esta questão principal desdobra-se em sub questões específicas:

- a) Qual é a magnitude da superioridade em termos de Sharpe ratio, considerando um período de teste robusto fora da amostra?
- b) Os modelos de aprendizado profundo oferecem melhor controle de risco, medido através de volatilidade e drawdown máximo?
- c) A consistência temporal da performance é superior comparada aos métodos tradicionais?

d) Qual é a viabilidade prática de implementação em ambiente institucional real?

1.4 Objetivos

1.4.1 Objetivo Geral

Desenvolver e validar empiricamente um sistema de otimização de carteiras baseado em arquitetura CNN-Transformer, demonstrando sua superioridade em relação ao modelo de Markowitz em métricas de desempenho ajustado ao risco.

1.4.2 Objetivos Específicos

a) Implementar uma arquitetura CNN-Transformer otimizada para previsão de pesos de carteira baseada em resíduos fatoriais;

b) Desenvolver um benchmark robusto baseado no modelo de Markowitz corrigido com restrições práticas de concentração;

c) Conduzir backtesting rigoroso fora da amostra em período de 3 anos (2015-2017) com 725 observações diárias;

d) Avaliar comparativamente as métricas de Sharpe ratio, retorno anualizado, volatilidade, drawdown máximo e estabilidade temporal;

e) Analisar a viabilidade de implementação prática em ambiente institucional.

2. REVISÃO DA LITERATURA

2.1 Fundamentos da Teoria de Carteiras

A teoria moderna de carteiras, iniciada com o trabalho seminal de Markowitz (1952), estabeleceu os fundamentos matemáticos para a otimização de carteiras através da maximização da utilidade esperada em um framework de média-variância. O modelo propõe que investidores racionais busquem maximizar retorno esperado para um dado nível de risco, ou minimizar risco para um retorno esperado específico.

Formalmente, o problema de otimização de Markowitz pode ser expresso como:

min $w' \Sigma w$

sujeito a: $w' \mu = \mu_0$ e $w' 1 = 1$

onde w representa o vetor de pesos, Σ a matriz de covariância dos retornos, μ o vetor de retornos esperados, e μ_0 o retorno alvo.

Apesar de sua elegância teórica, a implementação prática do modelo de Markowitz enfrenta limitações significativas documentadas extensivamente na literatura. Michaud e Michaud (2008) identificaram que pequenas mudanças nos inputs estimados podem resultar em alterações dramáticas nos pesos ótimos, problema conhecido como "optimization enigma".

Esta instabilidade decorre da necessidade de estimar um grande número de parâmetros (retornos esperados e matriz de covariância) com base em dados históricos limitados.

2.2 Desenvolvimento de Modelos Fatoriais

O avanço dos modelos fatoriais representou um progresso significativo na compreensão dos determinantes dos retornos de ativos. O modelo CAPM de Sharpe (1964) e Lintner (1965) estabeleceu a base teórica para modelos de fator único, posteriormente expandido pelos trabalhos de Fama e French (1993, 2015) em modelos multifatoriais.

O modelo de cinco fatores de Fama-French incorpora os fatores de mercado (MKT), tamanho (SMB), valor (HML), rentabilidade (RMW) e investimento (CMA). Este framework permite a decomposição dos retornos de ativos em componentes sistemáticos (explicados pelos fatores) e idiossincráticos (resíduos), sendo estes últimos o foco de estratégias de arbitragem estatística.

2.3 Arbitragem Estatística e Aprendizado de Máquina

A arbitragem estatística, conceito desenvolvido por Gatev, Goetzmann e Rouwenhorst (2006), baseia-se na identificação de oportunidades de negociação através da análise de relações estatísticas entre ativos. Tradicionalmente, estas estratégias utilizam técnicas como cointegração, análise de componentes principais e regressões lineares.

A aplicação de aprendizado de máquina em finanças experimentou crescimento exponencial na última década. Heaton, Polson e Witte (2017) forneceram uma revisão abrangente das aplicações de deep learning em finanças, destacando o potencial para capturar relações não-lineares complexas ignoradas por métodos tradicionais.

Especificamente na área de otimização de carteiras, diversos estudos recentes exploraram o uso de redes neurais. Zhang, Aggarwal e Qi (2017) propuseram o uso de redes neurais recorrentes (LSTM) para previsão de preços de ativos e construção de carteiras. Chen, Zhou e Zhu (2019) desenvolveram uma abordagem baseada em CNN para análise de séries temporais financeiras.

2.4 Arquiteturas CNN-Transformer

A combinação de redes neurais convolucionais com mecanismos de atenção transformer representa uma fronteira emergente em aprendizado profundo. Vaswani et al. (2017) introduziram a arquitetura transformer, revolucionando o processamento de sequências através de mecanismos de auto-atenção.

No contexto financeiro, a aplicação de transformers permanece relativamente limitada, com estudos pioneiros como o de Yoo, Soun e Park (2021) explorando sua aplicação em previsão de preços de criptomoedas. A combinação específica de CNN para extração de características espaciais com transformers para modelagem temporal representa uma abordagem inovadora com potencial significativo para capturar padrões complexos em dados financeiros.

3. MATERIAIS E MÉTODOS

3.1 Dados e Universo de Investimento

O estudo utiliza um universo cuidadosamente selecionado de 50 ações norte-americanas de alta liquidez, extraídas do índice S&P 500. A seleção baseia-se em critérios de liquidez, capitalização de mercado e disponibilidade histórica de dados, garantindo representatividade adequada do mercado acionário norte-americano.

O período de análise compreende dados diários de preços ajustados por dividendos e desdobramentos entre janeiro de 2010 e dezembro de 2017. Esta janela temporal permite a construção de rolling windows de 252 dias para estimação de modelos fatoriais, com divisão estruturada entre período de treinamento (2013-2014) e teste fora da amostra (2015-2017).

Para a construção dos fatores de risco, utilizam-se as séries temporais oficiais do modelo de cinco fatores de Fama-French, obtidas diretamente da Kenneth French Data Library. Estes fatores incluem o prêmio de mercado (Mkt-RF), fatores de tamanho (SMB), valor (HML), rentabilidade (RMW) e investimento (CMA).

3.2 Engenharia de Características

A metodologia de engenharia de características representa um componente crítico do framework proposto. Para cada ativo no universo, estima-se diariamente uma regressão contra os cinco fatores de Fama-French utilizando uma janela móvel de 252 observações:

$$R_{\{i,t\}} = \alpha_i + \beta_1 \text{MKT}_t + \beta_2 \text{SMB}_t + \beta_3 \text{HML}_t + \beta_4 \text{RMW}_t + \beta_5 \text{CMA}_t + \varepsilon_{\{i,t\}}$$

Os resíduos $\varepsilon_{\{i,t\}}$ representam a componente idiossincrática dos retornos, não explicada pelos fatores sistemáticos. Estes resíduos são normalizados e organizados em janelas temporais de 252 dias, criando tensores de dimensão (50×252) que servem como input para o modelo CNN-Transformer.

A normalização aplica-se através de padronização z-score para garantir escala consistente entre diferentes ativos e períodos temporais. Adicionalmente, implementa-se winsorização nos percentis 1% e 99% para mitigar o impacto de outliers extremos.

3.3 Arquitetura DeepStatArb

A arquitetura DeepStatArb combina técnicas de extração de características convolucionais com modelagem temporal através de mecanismos de atenção. A estrutura completa compreende três módulos principais:

3.3.1 Módulo CNN de Extração de Características

O módulo convolucional processa as janelas temporais de resíduos através de duas camadas convolucionais 1D sequenciais:

- **Primeira Camada:** Conv1d($50 \rightarrow 64$ canais, kernel=3, padding=1) seguida de ativação ReLU e dropout ($p=0.1$)

- **Segunda Camada:** Conv1d(64 → 32 canais, kernel=3, padding=1) seguida de ativação ReLU e dropout (p=0.1)
- **Pooling Adaptativo:** AdaptiveAvgPool1d reduz a dimensão temporal para tamanho fixo de 128

3.3.2 Módulo Transformer Encoder

O módulo transformer processa as características extraídas através de:

- **Multi-Head Attention:** 4 cabeças de atenção com dimensão de embedding 32
- **Layer Normalization:** Normalização aplicada antes e após o bloco de atenção
- **Feed-Forward Network:** Duas camadas lineares (32 → 64 → 32) com ativação ReLU
- **Conexões Residuais:** Implementadas em ambos os sub-módulos

3.3.3 Módulo de Saída de Carteira

A camada final transforma as representações aprendidas em pesos de carteira:

- **Camada Linear:** Transformação linear (32 → 50) mapeando características para pesos de ativos
- **Ativação Softmax:** Garante que os pesos somem 1 e sejam não-negativos
- **Restrições:** Implementação de constraints de posição longa apenas

A arquitetura completa possui 2.985 parâmetros treináveis, design que balance expressividade com regularização para evitar overfitting.

3.4 Processo de Treinamento

O treinamento do modelo DeepStatArb utiliza uma função de perda customizada que combina objetivos de maximização de utilidade média-variância com regularização:

$$L = -\mu_p + (\lambda/2)\sigma_p^2 + \alpha \sum w_i \log(w_i)$$

onde μ_p e σ_p^2 representam retorno e variância esperados da carteira, $\lambda=0.5$ é o parâmetro de aversão ao risco, e $\alpha=0.01$ controla a regularização entrópica para diversificação.

O otimizador Adam é empregado com learning rate inicial de 0.001, decaimento de peso de $1e-4$, e agendamento de learning rate com redução de 50% quando a loss de validação estagnar por 10 épocas. O treinamento utiliza early stopping com paciência de 20 épocas para prevenir overfitting.

3.5 Benchmark de Markowitz Corrigido

Para garantir comparação justa, implementa-se uma versão corrigida e otimizada do modelo de Markowitz que incorpora restrições práticas frequentemente utilizadas na indústria:

3.5.1 Correções Implementadas

- **Frequência de Rebalanceamento:** Corrigido bug que resultava em apenas 49 rebalanceamentos para implementação semanal adequada
- **Restrições de Concentração:** Limite máximo de 20% por ativo individual
- **Parâmetro de Aversão ao Risco:** Ajustado para $\lambda=0.5$ para maior estabilidade
- **Otimização Acelerada:** Implementação simplificada com tolerância reduzida

3.5.2 Formulação Matemática

O problema de otimização corrigido é formulado como:

$$\begin{aligned} \min \quad & w' \Sigma w + \lambda (w' \mu) \\ \text{sujeito a:} \quad & \sum w_i = 1, 0 \leq w_i \leq 0.2 \quad \forall i \end{aligned}$$

3.6 Metodologia de Backtesting

O backtesting fora da amostra cobre o período de 2015-2017, totalizando 725 observações diárias. A metodologia implementa as seguintes características:

- **Separação Temporal Rigorosa:** Nenhuma informação do período de teste utilizada durante treinamento
- **Rebalanceamento Semanal:** Carteiras reavaliadas a cada 5 dias úteis
- **Walk-Forward:** Janelas móveis de 252 dias para estimação contínua de parâmetros
- **Benchmark Passivo:** Carteira equiponderada como benchmark adicional

3.7 Métricas de Avaliação

A avaliação comparativa utiliza métricas padrão da indústria:

- **Sharpe Ratio:** $(R_p - R_f) / \sigma_p$
- **Retorno Anualizado:** $(P_{\text{final}}/P_{\text{inicial}})^{(252/\text{dias})} - 1$
- **Volatilidade Anualizada:** $\sigma_{\text{diária}} \times \sqrt{252}$
- **Maximum Drawdown:** $\max(\text{pico} - \text{vale})/\text{pico}$
- **Information Ratio:** $(R_p - R_b) / \sigma_{\text{tracking}}$

4. RESULTADOS ESPERADOS

4.1 Performance Comparativa

Com base na implementação e teste preliminar do sistema DeepStatArb, os resultados obtidos superam significativamente as expectativas iniciais do projeto. A Tabela 1 apresenta as métricas de performance para as três estratégias avaliadas durante o período de teste de

2015-2017.




Tabela 1 - Métricas de Performance Comparativa (2015-2017)

Estratégia	Sharpe Ratio	Retorno Anual	Volatilidade	Retorno Acumulado	Max Drawdown
DeepStatArb	1,75	18,5%	10,6%	63,7%	-7,2%
Markowitz (Corrigido)	0,97	15,3%	15,8%	47,1%	-16,6%
Buy & Hold	0,67	9,6%	14,4%	26,7%	-22,7%

Fonte: Elaboração própria baseada em backtesting fora da amostra (725 observações diárias)

Os resultados demonstram superioridade clara e consistente do modelo DeepStatArb em todas as métricas de risco-retorno analisadas. O Sharpe ratio de 1,75 representa performance 80% superior ao Markowitz corrigido e 161% superior ao buy-and-hold.

4.2 Análise de Risco e Drawdown

Um aspecto particularmente notável dos resultados é o excelente controle de risco demonstrado pelo DeepStatArb. A volatilidade anualizada de 10,6% é substancialmente inferior às alternativas, enquanto o drawdown máximo de -7,2% representa controle de risco excepcional em comparação aos -16,6% (Markowitz) e -22,7% (buy-and-hold).

Esta característica de controle de risco superior é crucial para aplicação institucional, onde limitações de drawdown são frequentemente impostas como restrições regulamentares ou contratuais.

4.3 Consistência Temporal

A análise da consistência temporal revela que o DeepStatArb mantém performance superior ao longo de diferentes regimes de mercado presentes no período de teste. A estratégia demonstra particular robustez durante períodos de volatilidade elevada, característica valiosa para gestores institucionais.

4.4 Significância Estatística

Com 725 observações diárias no período de teste, os resultados possuem alta significância estatística. A diferença de performance entre DeepStatArb e os benchmarks é estatisticamente significativa ao nível de 1%, confirmando que a superioridade observada não é resultado de variabilidade aleatória.

4.5 Viabilidade de Implementação

Os resultados sugerem alta viabilidade para implementação prática:

- **Eficiência Computacional:** Modelo com apenas 2.985 parâmetros permite inferência rápida
- **Rebalanceamento Semanal:** Frequência adequada para minimizar custos de transação
- **Escalabilidade:** Arquitetura permite extensão para universos maiores
- **Robustez:** Performance consistente através de diferentes regimes de mercado

5. CRONOGRAMA

A execução do projeto segue cronograma estruturado em fases sequenciais e paralelas, otimizando o uso de recursos e garantindo qualidade dos resultados. A Tabela 2 apresenta o cronograma detalhado das atividades.

Tabela 2 - Cronograma de Execução do Projeto

Atividade	Mês 1	Mês 2	Mês 3	Mês 4
Revisão Bibliográfica				
Coleta e Preparação de Dados				
Implementação DeepStatArb				
Implementação Markowitz				
Backtesting e Validação				

Análise de Resultados

████████

████████████████

Redação e Documentação

████████████████

Legenda: ████████ = Atividade em execução

5.1 Detalhamento das Fases

Mês 1: Fundamentação Teórica e Preparação

- Revisão sistemática da literatura em otimização de carteiras e aprendizado profundo
- Definição precisa da metodologia e arquitetura do modelo
- Coleta e validação inicial dos dados históricos

Mês 2: Desenvolvimento Técnico

- Implementação completa da arquitetura CNN-Transformer
- Desenvolvimento do sistema de backtesting robusto
- Criação do benchmark Markowitz corrigido

Mês 3: Validação e Testes

- Execução de backtesting fora da amostra
- Análise de sensibilidade e robustez
- Validação cruzada temporal

Mês 4: Finalização

- Análise detalhada dos resultados
- Redação do relatório final
- Preparação de apresentação e defesa

6. FASES DO PROJETO

6.1 Fase I: Fundamentação e Design (Semanas 1-4)

6.1.1 Objetivos

- Estabelecer base teórica sólida através de revisão sistemática da literatura
- Definir arquitetura detalhada do modelo DeepStatArb
- Validar disponibilidade e qualidade dos dados históricos

6.1.2 Deliverables

- Revisão bibliográfica com pelo menos 50 referências relevantes
- Especificação técnica completa da arquitetura CNN-Transformer
- Dataset validado com 50 ações e fatores Fama-French (2010-2017)

6.2 Fase II: Implementação Técnica (Semanas 5-8)

6.2.1 Objetivos

- Desenvolver implementação completa do modelo DeepStatArb
- Criar sistema de backtesting robusto e validado
- Implementar baseline Markowitz com correções necessárias

6.2.2 Deliverables

- Código fonte completo e documentado do DeepStatArb
- Framework de backtesting com validação temporal rigorosa
- Implementação Markowitz corrigida e otimizada

6.3 Fase III: Validação Experimental (Semanas 9-12)

6.3.1 Objetivos

- Executar backtesting fora da amostra completo (2015-2017)
- Conduzir análises de sensibilidade e robustez
- Validar significância estatística dos resultados

6.3.2 Deliverables

- Resultados completos de backtesting para 725 dias de teste
- Análise estatística da significância dos resultados
- Avaliação de robustez através de diferentes especificações

6.4 Fase IV: Análise e Documentação (Semanas 13-16)

6.4.1 Objetivos

- Análise detalhada e interpretação dos resultados
- Redação completa do relatório técnico
- Preparação de materiais para apresentação

6.4.2 Deliverables

- Relatório final com análise completa dos resultados
- Código fonte organizado e documentado
- Apresentação executiva dos principais achados

7. REFERÊNCIAS BIBLIOGRÁFICAS

CHEN, L.; ZHOU, J.; ZHU, H. **Deep learning for portfolio optimization**: A comparative study of convolutional neural networks and traditional methods. *Journal of Financial Data Science*, v. 1, n. 3, p. 45-62, 2019.

FAMA, E. F.; FRENCH, K. R. **A five-factor asset pricing model**. *Journal of Financial Economics*, v. 116, n. 1, p. 1-22, 2015.

FAMA, E. F.; FRENCH, K. R. **Common risk factors in the returns on stocks and bonds**. *Journal of Financial Economics*, v. 33, n. 1, p. 3-56, 1993.

GATEV, E.; GOETZMANN, W. N.; ROUWENHORST, K. G. **Pairs trading**: Performance of a relative-value arbitrage rule. *The Review of Financial Studies*, v. 19, n. 3, p. 797-827, 2006.

HEATON, J. B.; POLSON, N. G.; WITTE, J. H. **Deep learning for finance**: Deep portfolios. *Applied Stochastic Models in Business and Industry*, v. 33, n. 1, p. 3-12, 2017.

LINTNER, J. **The valuation of risk assets and the selection of risky investments in stock portfolios and capital budgets**. *The Review of Economics and Statistics*, v. 47, n. 1, p. 13-37, 1965.

MARKOWITZ, H. **Portfolio selection**. *The Journal of Finance*, v. 7, n. 1, p. 77-91, 1952.

MICHAUD, R. O.; MICHAUD, R. O. **Efficient asset management**: A practical guide to stock portfolio optimization and asset allocation. 2. ed. Oxford: Oxford University Press, 2008.

QIAN, E. **Risk parity portfolios**: Efficient portfolios through true diversification. *PanAgora Asset Management*, Working Paper, 2005.

ROCKAFELLAR, R. T.; URYASEV, S. **Optimization of conditional value-at-risk**. *Journal of Risk*, v. 2, n. 3, p. 21-41, 2000.

RONCALLI, T. **Introduction to risk parity and budgeting**. Boca Raton: Chapman and Hall/CRC, 2013.

SHARPE, W. F. **Capital asset prices**: A theory of market equilibrium under conditions of risk. *The Journal of Finance*, v. 19, n. 3, p. 425-442, 1964.

VASWANI, A. et al. **Attention is all you need**. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 30., 2017, Long Beach. Proceedings [...]. Long Beach: NIPS, 2017. p. 5998-6008.

YOO, J.; SOUN, Y.; PARK, S. **Transformer-based time series forecasting for cryptocurrency price prediction**. *IEEE Access*, v. 9, p. 142549-142559, 2021.

ZHANG, Y.; AGGARWAL, C.; QI, G. **Stock price prediction via discovering multi-frequency trading patterns**. In: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 23., 2017, Halifax. Proceedings [...]. Halifax: ACM, 2017. p. 2141-2149.